

“**Build with Us | Deep Dive: Building Your First Pipeline**”是发布在 learn.palantir.com 上的一门深度实战课程, 由 **Ontologize** 团队(由前 Palantir 工程师组成)提供 1。该课程旨在指导用户如何在 Palantir Foundry 中通过核心工作流, 从零开始构建、部署并管理一个完整的数据生产管道 1。

以下是基于提供的来源对该课程内容的详细介绍:

1. 核心概念与管道定义

课程首先明确了 Foundry 中“管道(Pipeline)”的基础定义:

- 定义: 管道是一系列输入数据集(或单个数据集), 通过一系列**转换(Transformations)**处理后, 生成一个或多个输出数据集的过程 2。
- 循环特性: 输出数据集可以进一步作为下一个管道环节的输入, 直到生成能够支撑最终业务流的数据集序列 2。
- 构建目的: 管道通常用于清洗原始数据、为数据分析做准备、为本体(**Ontology**)对象类型提供支撑, 或作为机器学习模型的输入 3。

2. 开发环境与准备工作

- 工具: 课程的核心操作是在 **Pipeline Builder** 应用中完成的, 这是一个用于构建数据管道的图形化/低代码环境 4, 5。
- 权限要求: 用户需要拥有对应项目的 **Editor**(编辑) 角色, 以便能够添加和管理 Pipeline Builder 构件 6。
- 建议存储位置: 通常在名为 temporary training artifacts 或 tutorial practice artifacts 的公共训练项目下创建个人文件夹进行练习 3, 6。

3. 数据摄取与初始预处理

课程通过三种不同格式的原始数据(产品、客户、交易数据)演示了摄取流程:

- 支持格式: 包括 **CSV**、**Parquet**(一种专为 Spark 引擎优化的列式存储格式)和 **JSON** 7。
- 数据清洗(**Cleaning**):
- 去除空格(**Trim Whitespace**): 确保字段名称一致, 防止在后续聚合分组时出现错误 8, 9。
- 类型转换(**Cast**): 将字符串类型的字段(如价格 Price 或单位 Units)转换为数值类型(如 Double), 以便进行数学运算 8, 10, 11。
- 过滤(**Filter**): 移除包含空值(Null)或无效数据的行, 以维护数据质量 12。

4. 高级转换与 AI 集成

课程涵盖了一些复杂的处理技巧:

- 处理结构化数据(**Structs**): 教授如何解析嵌套的 JSON 数据, 使用 **Flatten struct**(展平结构体)和 **Concatenate**(拼接)功能将复杂的地址字段转换为易读的字符串 13, 14, 15。
- **AIP** 助手辅助开发:
- 自动生成转换逻辑: 用户可以利用 **Foundry AI** 助手 通过自然语言生成复杂的转换逻辑, 例如将具有特殊格式的字符串日期转换为标准的时间戳(Timestamp) 16, 11。
- 提示词构建: AI 助手可以根据用户提供的示例值自动推断并生成日期格式字符串, 极大简化了开发难度 16。

5. 数据集成与逻辑优化

在单表清洗完成后，课程进入数据整合阶段：

- 多表连接(**Joins**)：通过 **Left Join** (左连接) 将交易、产品和客户数据合并，构建全局视图 17, 18。
- 故障排除(**Troubleshooting**)：教授如何利用 **View Stats** (查看统计数据) 功能识别“连接爆炸”或数据重复 (Multiplicity) 问题，并据此调整连接键 (如将 `product_id` 更改为更精确的 `product_variation_id`) 19, 20, 21。
- 数据聚合(**Aggregations**)：执行类似 SQL 中 Group By 的操作，通过计算“单价 × 数量”得到收入，并按客户维度汇总生成**客户终生价值 (Customer Lifetime Value)** 数据集 22, 23。

6. 部署、监控与最佳实践

- 部署(**Deploy**)：在 Pipeline Builder 中，逻辑编写完成后必须点击“Deploy”才能在 Foundry 中实际运行并生成物化数据集 24。
- 作业追踪(**Job Tracker**)：课程引导用户通过 Job Tracker 监控后台 Spark 作业的执行进度和成功状态 25。
- 管道分段(**Pipeline Segmentation**)：作为最佳实践，建议将大型管道拆分为多个逻辑段 (如原始层 Raw、清洗层 Clean、富化层 Enriched、本体层 Ontology)，以便于维护和协作 26, 27。
- 数据血缘(**Data Lineage**)：通过血缘应用可视化展示从原始数据到最终分析应用的全过程，确保数据的可追溯性 27。

通过本教程，用户能够掌握在 Foundry 平台中构建高性能、受治理且可扩展的工业级数据管道所需的端到端技能 28。