

“Build with Us | Deep Dive: Building Your First Pipeline”是发布在 learn.palantir.com 上的一门深度实战课程, 由前 Palantir 工程师组成的 **Ontologize** 团队制作 1, 2。该课程的核心目标是指导用户在 Palantir Foundry 中利用 **Pipeline Builder** 应用, 从零开始构建一个完整的数据生产管道 3, 4。

以下是基于来源对该课程内容的详细介绍:

1. 核心概念与管道定义

课程首先明确了 Foundry 中“管道(Pipeline)”的定义: 它是一系列输入数据集通过一系列转换(**Transformations**)最终生成输出数据集的过程 5。

- 构建目的: 管道通常是为了使原始数据(Raw Data)变得可用, 例如为分析做准备、支撑本体(Ontology)对象类型, 或作为机器学习模型的输入 5, 6。
- 开发环境: 主要在 **Pipeline Builder** 中进行, 这是一个低代码/图形化的开发环境 3, 4。

2. 数据准备与清洗流程 (Preprocessing)

课程通过三种不同格式的原始数据(产品 CSV/Parquet、客户结构化数据、交易 JSON)演示了数据清洗的最佳实践:

- 基础转换: 包括修剪字符串空格(Trim Whitespace)以确保聚合准确, 以及将数据类型(如价格)从字符串转换为双精度浮点型(Double) 7-10。
- 复杂结构处理: 教授如何处理“结构体(Struct)”数据 11。例如, 将嵌套的 JSON 地址信息展平(Flatten), 解析后重新拼接成易读的街道/城市/州字符串, 并删除冗余的中间列 12-16。
- **AI** 辅助功能: 展示了如何利用 **Foundry AI** 助手 自动生成复杂的日期转换格式字符串(Timestamp Casting), 减少了查阅技术文档的负担 17-20。

3. 数据集成与逻辑优化 (Joins & Aggregations)

在清洗完各分支数据后, 课程进入了数据整合阶段:

- 多表连接 (**Joins**): 将交易记录、产品信息和客户资料通过左连接(Left Join)合并 21, 22。
- 故障排除与调试: 课程特别强调了如何使用 **View Stats**(查看统计数据) 功能来识别数据重复(Multiplicity)问题 23, 24。例如, 当发现 Join 导致行数非预期增加时, 引导用户将连接键从 product_id 优化为更精确的 product_variation_id 24, 25。
- 高级聚合: 通过数学运算(单价 × 数量)计算收入(Revenue), 并按客户进行分组聚合, 最终生成客户终生价值 (**Customer Lifetime Value**) 数据集 26, 27。

4. 部署、监控与最佳实践

课程不仅涵盖了逻辑编写, 还包括了管道的运维管理:

- 部署 (**Deployment**): 逻辑编写完成后, 必须通过“部署”操作才能在 Foundry 中物化(Materialize)出实际的数据集 28, 29。
- 作业追踪 (**Job Tracker**): 介绍如何使用 Job Tracker 查看后台 Spark 作业的执行进度和详细信息 29。
- 管道分段 (**Segmentation**): 讲解了将大型管道拆分为多个逻辑段(如原始层、清洗层、富化层、本体层)的最佳实践, 以便于维护和复用 30, 31。
- 数据血缘 (**Data Lineage**): 通过血缘视图提供管道的端到端可视化, 确保数据的来源和去向清晰透明 31, 32。

5. 学习建议

- 权限准备: 用户需要拥有 Foundry 项目的“编辑(Editor)”权限, 并能访问 Pipeline Builder 应用 33。
- 实验环境: 建议在“临时训练工件(Temporary Training Artifacts)”或特定的教学文件夹中进行操作, 以保持环境整洁 4, 6, 33。

通过学习该课程, 用户不仅能掌握 **Pipeline Builder** 的功能, 还能学会如何构建一个高性能、受治理且可扩展的工业级数据管道 32。